



**POLITECHNIKA
RZESZOWSKA**
im. IGNACEGO ŁUKASIEWICZA



**WYDZIAŁ
MATEMATYKI
I FIZYKI STOSOWANEJ**
POLITECHNIKI RZESZOWSKIEJ

POLITECHNIKA RZESZOWSKA
im. Ignacego Łukasiewicza
WYDZIAŁ MATEMATYKI I FIZYKI STOSOWANEJ

Rafał Bazan

**OPRACOWANIE SYSTEMU ADAPTACYJNEGO
STEROWANIA ROJEM DRONÓW Z WYKORZYSTANIEM
INTERFEJSU GŁOSOWEGO I SELEKCJI ALGORYTMÓW
NAWIGACYJNYCH.**

Promotor: dr hab. inż. Damian Kordos

PRACA INŻYNIERSKA

kierunek studiów: Inżynieria i Analiza Danych

Rzeszów 2025

Miejsce na ewentualne podziękowania.
W przypadku braku podziękowań, tę stronę wraz z następującą po niej pustą stroną
należy usunąć z wersji końcowej pracy.

Spis treści

Wstęp	7
1. Teoretyczne podstawy interakcji człowiek-rój (HSI) oraz architektury agentowo-robotycznej	9
1.1. Bariery kognitywne i ograniczenia poznawcze w wielodronowych systemach sterowania	9
1.2. Modele komunikacji głosowej i interfejsy HRI w standardzie ROS . . .	10
1.3. Paradygmat Embodied AI i rola wielkich modeli językowych (LLM) w sterowaniu	11
1.4. Algorytmy inteligencji stadnej i optymalizacja zachowań rojowych . . .	12
2. Technologie, narzędzia i środowiska symulacyjne	13
2.1. Robot Operating System 2 (ROS2) jako przemysłowy standard middleware	13
2.2. Architektura systemu nawigacyjnego Nav2 i wykorzystanie Drzew Zachowań (Behavior Trees)	13
2.3. Framework RAI i integracja agentów LLM ze stosem robotycznym . . .	13
2.4. Platforma ds-crazyflies i charakterystyka fizyczna platform UAV	13
3. Autorski projekt systemu adaptacyjnego sterowania rojem	15
3.1. Architektura informatyczna rozwiązania – warstwy abstrakcji i przepływ danych	15
3.2. Moduł interfejsu głosowego – fuzja mowy, generowanie wektorów i mapowanie intencji	15
3.3. Silnik decyzyjny LLM i selekcja algorytmów nawigacyjnych oparta na RAG	15
3.4. Implementacja adaptacyjnego algorytmu dyskretnej optymalizacji roju (DPSO)	15
4. Walidacja, scenariusze operacyjne i analiza wyników	17
4.1. Metodologia badań i metryki oceny wydajności roju (świadomość sytuacyjna, czas misji)	17
4.2. Scenariusz 1: Statyczna eksploracja i zarządzanie formacją ($O(1)$ complexity)	17
4.3. Scenariusz 2: Dynamiczna adaptacja do awarii podzespołów i re-alokacja zadań	17

4.4. Ocena redukcji obciążenia poznawczego operatora	17
Podsumowanie i kierunki dalszych badań	19
Bibliografia	20

Wstęp

Współczesne systemy bezzałogowych statków powietrznych (UAV) ulegają dynamicznej transformacji, ewoluując od pojedynczych, zdalnie sterowanych jednostek w kierunku autonomicznych rojów zdolnych do realizacji złożonych misji rozproszonych. Rosnąca liczba agentów operujących we wspólnej przestrzeni powietrznej wymusza porzucenie tradycyjnego modelu sterowania, w którym jeden operator kontroluje jedną maszynę, na rzecz paradygmatu interakcji człowiek-rój (ang. *Human-Swarm Interaction*, HSI). Niestety, klasyczne interfejsy sterowania wprowadzają drastyczne obciążenie poznawcze operatora, co przy zarządzaniu rojem prowadzi do natychmiastowej utraty świadomości sytuacyjnej oraz spadku zaufania do automatyzacji. Gwałtowny rozwój wielkich modeli językowych (LLM) stwarza bezprecedensową okazję do zaprojektowania w pełni naturalnych, głosowych interfejsów komunikacyjnych (HRI), które działając jako semantyczny bufor między człowiekiem a algorytmami rojowymi, pozwalają na wydawanie wysokopoziomowych dyrektyw zamiast mikrozarządzania trajektoriami.

Głównym celem niniejszej pracy jest opracowanie, implementacja i ewaluacja systemu adaptacyjnego sterowania rojem dronów. System ten integruje interfejs głosowy wspierany modelami LLM z modułem dynamicznej selekcji algorytmów nawigacyjnych. Zdefiniowana w pracy hipoteza badawcza zakłada, że włączenie frameworku agentowego (RAI) integrującego LLM ze środowiskiem ROS2 i systemem Nav2, połączone z adaptacyjnymi algorytmami inteligencji stadnej (m.in. DPSO), pozwala na redukcję złożoności sterowania z poziomu liniowego $O(n)$ do poziomu stałego $O(1)$ z punktu widzenia operatora, przy jednoczesnym zwiększeniu efektywności i bezpieczeństwa misji.

Szczegółowy zakres pracy obejmuje zaprojektowanie architektury informatycznej łączącej platformę **ds-crazyflies** z warstwą percepcyjną i decyzyjną. Moduł decyzyjny będzie autonomicznie oceniał stan otoczenia i na bazie poleceń głosowych dobierał odpowiednią strategię nawigacyjną.

Struktura pracy została podzielona na cztery zasadnicze rozdziały. Rozdział pierwszy stanowi rygorystyczny przegląd literatury z zakresu barier kognitywnych, interfejsów HRI, koncepcji Embodied AI oraz optymalizacji rojowej. W rozdziale drugim scharakteryzowano zastosowane technologie, w tym ROS2, framework RAI oraz stos nawigacyjny Nav2. Rozdział trzeci, stanowiący inżynierski rdzeń pracy, opisuje autorską architekturę i implementację adaptacyjnego systemu decyzyjnego. Rozdział

czwarty zawiera analizę wyników przeprowadzonych badań symulacyjnych w zróżnicowanych scenariuszach operacyjnych, weryfikując przyjęte założenia projektowe.

Rozdział 1

Teoretyczne podstawy interakcji człowiek-rój (HSI) oraz architektury agentowo-robotycznej

1.1. Bariery kognitywne i ograniczenia poznawcze w wielodronowych systemach sterowania

Przejsie od zdalnego sterowania (ang. *teleoperation*) do sterowania nadzorczego (ang. *supervisory control*) stanowi fundamentalny wymóg w rozwoju zaawansowanych systemów UAV. W tradycyjnym ujęciu, złożoność poznawcza sterowania niezależnymi robotami skaluje się liniowo ze wzorem $O(n)$, gdzie n to liczba jednostek. Wymaga to od operatora alokacji zasobów uwagi wprost proporcjonalnie do wielkości floty, co w warunkach krytycznych prowadzi do drastycznego przeciążenia kognitywnego (ang. *cognitive overload*). Zgodnie z badaniami przeprowadzonymi przez Kollinga i in., nadrzędnym celem inżynierii systemów rojowych jest sprowadzenie tej złożoności do poziomu $O(1)$, w którym operator zarządza całym rojem (lub jego podzbiorami – ang. *subswarms*) jako pojedynczą, zintegrowaną encją [1].

Pojemność ludzkiej pamięci roboczej w kontekście jednoczesnej kontroli wielokrotnych bezzałogowców jest ściśle ograniczona. Badania empiryczne wykazują, że ludzki operator jest w stanie skutecznie śledzić do 16 obiektów wyłącznie w przypadku najprostszych zadań selekcji, do 7 w operacjach o średniej złożoności, natomiast w przypadku heterogenicznych, zaawansowanych misji – zaledwie do 4 jednostek [3]. Próba przekroczenia tych barier, określana problematyką wielozadaniowości (ang. *multitasking*), skutkuje skokową degradacją świadomości sytuacyjnej (ang. *Situation Awareness - SA*), w szczególności podczas tzw. przełączania zadań (ang. *task switching*) [2]. W interakcji z zaawansowaną automatyzacją zjawisko to rodzi dodatkowe zagrożenia, takie jak *cognitive tunneling* (zawężenie uwagi do jednego wskaźnika) oraz nadmierna ufność w system (ang. *complacency*), która zwiększa ryzyko występowania błędów decyzyjnych (tzw. zjawiska *false-alarm* i *miss-prone*) [2].

Rozwiązaniem tego problemu jest wdrożenie paradygmatu współpracy wielu operatorów z wieloma platformami (M:N) oraz architektury zespołu

ludzko-autonomicznego (ang. *Human-Autonomy Teaming, HAT*), wprowadzającej role takich jak monitory czy menedżerowie lotu [4]. Odpowiednio zaprojektowany interfejs w takim zespole pozwala na zastosowanie zarządzania przez wyjątki (ang. *Management by Exception - MBE*) lub zgody (ang. *Management by Consent - MBC*) [2]. Co więcej, wprowadzono koncepcję tzw. „dobroczynnego zaniedbania” (ang. *neglect benevolence*), która zakłada, że w systemach rojowych o wysokim wskaźniku autonomii, czasowa nieobecność interwencji operatora często pozwala rojom skuteczniej osiągać optymalne, globalne stany stabilności [1].

1.2. Modele komunikacji głosowej i interfejsy HRI w standardzie ROS

Aby zrealizować model sterowania na poziomie $O(1)$, konieczne jest zastąpienie klasycznych joysticków interfejsami o wysokim poziomie semantycznym. Interakcja Człowiek-Robot (ang. *Human-Robot Interaction, HRI*) opiera się obecnie na dwukierunkowej komunikacji (ang. *bidirectional communication*), która pozwala robotowi nie tylko na pasywny odbiór komend, lecz także na informowanie człowieka o swoich zamiarach (ang. *intent expression*) [5].

W nowoczesnych architekturach robotycznych dąży się do multimodalnej fuzji danych percepcyjnych. Integracja sygnałów fonicznych z estymacją postawy, mimiką czy wskaźnikami biologicznymi (np. sygnałami EEG) pozwala na zbudowanie wysoce odpornego modelu predykcyjnego stanów emocjonalnych i intencji operatora [5]. Ekosystem Robot Operating System (ROS) standaryzuje to podejście poprzez zbiór konwencji ROS4HRI (w szczególności REP-155). Umożliwia to zunifikowany przesył danych za pośrednictwem dedykowanych bibliotek takich jak `hri_msgs` czy pakietów śledzących, m.in. `hri_person_manager` [5].

Krytycznym aspektem rozwoju systemów rozpoznawania mowy dla rojów dronów na polu walki i w warunkach infrastruktury krytycznej są kwestie etyki i bezpieczeństwa. W dobie rygorystycznych wymogów prawnych (m.in. RODO/GDPR), preferowanym wzorcem architektonicznym jest Przetwarzanie na Krawędzi (ang. *Edge Computing*), które gwarantuje asynchroniczną ewaluację modeli ML (Machine Learning) bez konieczności przesyłania wrażliwych danych biometrycznych poza sieć lokalną roju. Podejście to, znane jako *Privacy by Design*, minimalizuje ryzyko wektorów ataków cyfrowych na komunikację akustyczną [5].

1.3. Paradygmat Embodied AI i rola wielkich modeli językowych (LLM) w sterowaniu

Tłumaczenie nieskodyfikowanej mowy ludzkiej na formalne wywołania węzłów ROS2 wymaga warstwy pośredniczącej, wyposażonej w szeroki aparat kognitywny. Włączenie Wielkich Modeli Językowych (LLM) otwiera nowe możliwości w zakresie podejmowania decyzji wieloagentowych (ang. *Multi-Agent Decision-Making, MADM*). W modelu tym algorytmy LLM ewoluują od prostych interpreterów poleceń do funkcji *policy generators* oraz *critics*, stymulujących mechanizmy tzw. uczenia w kontekście (ang. *in-context learning*) oraz implementacji obliczeniowej Teorii Umysłu (ang. *Theory of Mind - ToM*) u agentów sztucznych [7].

Zastosowanie LLM w robotyce wymusiło powstanie paradygmatu Sztucznej Inteligencji Ucieleśnionej (ang. *Embodied AI*). Samo oprogramowanie LLM nie dysponuje fizyczną świadomością granic czasoprzestrzennych, stąd jego integracja w zamkniętej pętli wymaga dedykowanych architektur pośrednich. Jednym z wiodących rozwiązań w tej dziedzinie jest framework RAI [6]. Architektura RAI pozwala na kategoryzację systemów inteligentnych na agenty konwersacyjne (ang. *Conversational Agents*) i oparte na stanach (ang. *State-Based Agents*). Poprzez wbudowane mechanizmy integracyjne (ang. *Connectors*), w tym zwłaszcza integrację warstwy ROS2Connector, framework ten pozwala na bezproblemową komunikację modeli generatywnych z komponentami sprzętowymi [6].

Centralnym wyzwaniem pozostaje zjawisko tzw. halucynacji AI, czyli konfabulowania przez modele nielogicznych i z fizycznego punktu widzenia niewykonalnych instrukcji nawigacyjnych. Aby ograniczyć to zjawisko, ucieleśnienie odbywa się przy pomocy technik Generowania Wzbogaconego Wyszukiwaniem (ang. *Retrieval-Augmented Generation, RAG*). Mechanizm ten wykorzystuje zaawansowane, wielowymiarowe bazy wektorowe (np. *Faiss*) do semi-automatycznego wstrzykiwania do *system promptów* wiedzy kontekstowej o parametrach roju, limitach kinematycznych i dostępnych zachowaniach (ang. *Tools*). Pozwala to LLM na deterministyczne przyporządkowywanie otwartych instrukcji głosowych do zamkniętego zbioru algorytmów operacyjnych drona [6].

1.4. Algorytmy inteligencji stadnej i optymalizacja zachowań rojowych

Na najniższym poziomie abstrakcji układu decyzyjnego, polecenia przetworzone przez LLM zostają delegowane do systemu planowania trajektorii i alokacji celów przestrzennych roju. Biologicznie inspirowana Inteligencja Stadna (ang. *Swarm Intelligence*) wykorzystuje samoorganizujące się jednostki z ograniczonymi receptorami do powstawania skomplikowanych emergentnych zachowań globalnych [9, 10]. W naturze zachowania takie – jak formowanie klucza w kształcie litery V przez ptaki migrujące (optymalizacja oporów aerodynamicznych) lub systemy podziału ról (ang. *division of labor*) u insektów – opierają się nierzadko na tzw. stygmergii, tj. niebezpośredniej komunikacji poprzez modyfikację fizycznego środowiska [9, 10].

W warunkach symulowanej autonomii roju, zadania re-alokacji i nawigacji dynamicznej modelowane są najczęściej w matematycznej domenie Dynamicznego Problemu Komiwojażera (ang. *Dynamic Traveling Salesman Problem, DTSP*) [8]. Adaptacja do szybko zmieniających się warunków operacyjnych wymaga wysoce nieliniowych metaheurystyk. Do czołowych z nich należy algorytm Dyskretnej Optymalizacji Roju Cząstek (ang. *Discrete Particle Swarm Optimization, DPSO*) [8].

Mechanika algorytmu DPSO, stosowana w kontekście nawigacji rojowej UAV, wykorzystuje rozbudowane struktury sąsiedztwa i heterogeniczną adaptację parametrów, co chroni sub-roje przed przedwczesną zbieżnością w minimach lokalnych. Co więcej, wzbogacenie algorytmu DPSO o mechanizmy tzw. pamięci feromonowej potęguje efektywność przeszukiwania topologii grafu operacyjnego poprzez nakładanie kar i nagród dla eksplorowanych węzłów ścieżki [8]. W celu estymacji optymalnych ścieżek stosuje się zaawansowane relaksacje metryczne, w tym tzw. estymację odległości opartą o dolne ograniczenia *Held-Karp* oraz α -miarę *Helsgauna*, co pozwala modelom LLM na deterministyczną ewaluację propozycji planu przed wysłaniem komend wykonawczych do węzłów środowiska ROS2 [8].

Rozdział 2

Technologie, narzędzia i środowiska symulacyjne

- 2.1. Robot Operating System 2 (ROS2) jako przemysłowy standard middleware
- 2.2. Architektura systemu nawigacyjnego Nav2 i wykorzystanie Drzew Zachowań (Behavior Trees)
- 2.3. Framework RAI i integracja agentów LLM ze stosem robotycznym
- 2.4. Platforma ds-crazyflies i charakterystyka fizyczna platform UAV

Rozdział 3

Autorski projekt systemu adaptacyjnego sterowania rojem

- 3.1. Architektura informatyczna rozwiązania – warstwy abstrakcji i przepływ danych
- 3.2. Moduł interfejsu głosowego – fuzja mowy, generowanie wektorów i mapowanie intencji
- 3.3. Silnik decyzyjny LLM i selekcja algorytmów nawigacyjnych oparta na RAG
- 3.4. Implementacja adaptacyjnego algorytmu dyskretnej optymalizacji roju (DPSO)

Rozdział 4

Walidacja, scenariusze operacyjne i analiza wyników

- 4.1. Metodologia badań i metryki oceny wydajności roju (świadomość sytuacyjna, czas misji)
- 4.2. Scenariusz 1: Statyczna eksploracja i zarządzanie formacją ($O(1)$ complexity)
- 4.3. Scenariusz 2: Dynamiczna adaptacja do awarii podzespołów i re-alokacja zadań
- 4.4. Ocena redukcji obciążenia poznawczego operatora

Podsumowanie i kierunki dalszych badań

Bibliografia

- [1] A. Kolling, P. Walker, N. Chakraborty, K. Sycara, and M. Lewis, „Human interaction with robot swarms: A survey,” *IEEE Transactions on Human-Machine Systems*, vol. 46, no. 1, pp. 9–26, Feb. 2016.
- [2] J. Y. C. Chen, M. J. Barnes, and M. Harper-Sciarini, „Supervisory Control of Unmanned Vehicles,” U.S. Army Research Laboratory, Tech. Rep. ARL-TR-5136, 2010.
- [3] Defense Intelligence Agency, „Cognitive Limits on Simultaneous Control of Multiple Unmanned Spacecraft,” Defense Intelligence Reference Document, DIA-08-1101-001, 2010.
- [4] C. L. Smith *et al.*, „A Cognitive Walkthrough of Multiple Drone Delivery Operations,” in *AIAA Aviation 2021 Forum*, Aug. 2021.
- [5] M. Pomianek, „Analiza literatury HRI,” Politechnika Rzeszowska, Tech. Rep., 2026.
- [6] K. Rachwał *et al.*, „RAI: Flexible Agent Framework for Embodied AI,” Robotec.AI, Warsaw, Poland, arXiv:2505.07532v1, 2025.
- [7] C. Sun, S. Huang, and D. Pompili, „LLM-Based Multi-Agent Decision-Making: Challenges and Future Directions,” *IEEE Robotics and Automation Letters*, vol. 10, no. 6, 2025.
- [8] Ł. L. Strąk, „Adaptacyjny algorytm optymalizacji stadnej cząsteczek dla dynamicznego problemu komiwojażera,” Rozprawa doktorska, Uniwersytet Śląski, Wydział Informatyki i Nauki o Materiałach, 2017.
- [9] E. Bonabeau, M. Dorigo, and G. Theraulaz, *Swarm Intelligence: From Natural to Artificial Systems*. New York, NY, USA: Oxford University Press, 1999.
- [10] J. Kennedy and R. C. Eberhart, *Swarm Intelligence*. San Francisco, CA, USA: Morgan Kaufmann Publishers, 2001.

POLITECHNIKA RZESZOWSKA

Rzeszów 2025

im. Ignacego Łukasiewicza

WYDZIAŁ MATEMATYKI I FIZYKI STOSOWANEJ

STRESZCZENIE PRACY DYPLOMOWEJ

Tytuł: Tytuł pracy

Autor: Imię Nazwisko

Promotor: dr hab. Imię Nazwisko, prof. PRz

Słowa klucze: słowo1, słowo2, słowo3

(Tekst streszczenia w języku polskim)

RZESZOW UNIVERSITY OF TECHNOLOGY

Rzeszów 2025

FACULTY OF MATHEMATICS AND APPLIED PHYSICS

DIPLOMA THESIS ABSTRACT

Title: Tytuł pracy po angielsku

Author: Imię Nazwisko

Supervisor: Imię Nazwisko, PhD, DSc, Assoc. Prof.

Key words: słowa klucze po angielsku

(Tekst streszczenia w języku angielskim)

Wykaz obszarów i narzędzi GenAI
wykorzystanych przez autora w trakcie wykonywania pracy dyplomowej

Lp.	Obszar wykorzystywania ^{a)}	Narzędzie

Uwaga! W przypadku, gdy autor nie korzysta z obszarów i narzędzi GenAI w tabeli wpisuje „nie korzystano”

^{a)} *Przykładowe obszary wykorzystania:*

- a) redakcja i korekta tekstu (m.in. poprawa stylistyczna i gramatyczna, synonimy i parafrazowanie, sprawdzenie spójności językowej),*
- b) analiza stanu wiedzy, przegląd literatury,*
- c) generowanie treści lub przykładów,*
- d) tworzenie pytań do ankiet i kwestionariuszy,*
- e) tworzenie schematów, diagramów i map myśli,*
- f) analiza danych i wizualizacja wyników (m.in. obliczenia statystyczne, tworzenie wykresów i tabel),*
- g) tworzenie podsumowań i wniosków,*
- h) pisanie i testowanie kodu,*
- i) tłumaczenia językowe.*